

金融情緒與股價趨勢系統：基於行為財務學與自然語言處理之深度研究與工程實踐

系統工程與金融理論之交匯背景

在當代量化金融與資料工程（Data Engineering）的高速發展下，建構具備高吞吐量、低延遲且具備容錯機制的自動化資料管線（Data Pipeline），已成為金融科技領域的關鍵基礎設施。傳統的資本市場定價模型高度仰賴結構化數據，如企業財務報表、總體經濟指標以及歷史價量資料。然而，隨著網際網路時代的來臨，散戶投資人大量聚集於社群平台與網路論壇（如台灣的 PTT 股板、美國的 Reddit 或 Twitter），這些非結構化的文本資料蘊含了極為龐大的市場情緒與群眾心理。對於現代資料工程師而言，如何將這些非結構化的「雜訊」轉化為結構化的「特徵」，並以此為基礎建立穩健的機器學習預測模型，是一項極具挑戰性且高價值的工程任務。

本報告以「金融情緒與股價趨勢系統」此一端到端（End-to-End）專案為核心探討對象。該系統在架構設計上採用了模組化（Modularity）與關注點分離（Separation of Concerns）的現代軟體工程原則，成功實作了包含收集層（Extract）、轉換層（Transform）與載入層（Load）的完整 ETL 管線¹。在系統的第一階段與第二階段中，不僅整合了 YFinance API 與台灣證交所資料，更設計了防禦反爬蟲機制的 PTT 網頁爬蟲，並獨創性地導入了混合式自然語言處理（Hybrid NLP）管線，透過 SnowNLP 初篩結合大型語言模型（LLM, 如 Gemini）進行批次情緒判讀，最終以冪等性（Idempotency）架構寫入 PostgreSQL 資料倉儲¹。

為確保該系統不僅在軟體工程架構上無懈可擊，在金融領域的應用上亦能具備高度的專業性與學理可信度，本報告將深入盤點關於「股票漲跌與市場情緒」的核心學術研究。透過梳理行為財務學（Behavioral Finance）的經典模型、網路文本情緒量化的實證文獻，以及最先進的機器學習與時間序列驗證策略，本報告旨在為該系統後續即將開展的機器學習層（Phase 3）與商業智慧視覺化層（Phase 4）提供堅實的理論基礎與實作藍圖。這些被學術界廣泛驗證或正在接受檢驗的背景知識，將直接指導系統的特徵工程（Feature Engineering）、資料聚合（Data Aggregation）邏輯，以及模型驗證機制，使本專案完全符合機構級量化分析的嚴謹標準。

行為財務學視角：從效率市場到雜訊交易者模型

探討網路情緒是否能有效預測股價之前，必須先確立其背後的經濟學與財務學邏輯。傳統金融學的核心支柱為「效率市場假說」（Efficient Market Hypothesis, EMH）。該假說主張，在一個完全競爭且資訊流通無礙的市場中，資產價格已經即時且充分地反映了所有可獲得的資訊³。在強式或半強式效率市場的假設下，股價的變動遵循隨機漫步（Random Walk），這意味著投資人無法透過分析歷史價格（技術分析）或公開資訊（基本面分析與新聞）來獲取超額報酬（Alpha），因為所有資訊在公開的瞬間就已被市場消化並定價。

然而，現實市場中層出不窮的資產泡沫、股市崩盤以及長期的價格異象，使效率市場假說面臨嚴峻挑戰。行為財務學應運而生，放寬了「投資人皆為完全理性」的假設，指出市場參與者的決策深受認知偏見（Cognitive Biases）、過度自信（Overconfidence）與情緒波動的影響。

在行為財務學的發展歷程中，De Long, Shleifer, Summers, 與 Waldmann 於 1990 年共同發表的「雜訊交易者風險」（Noise Trader Risk）模型（學界常簡稱為 DSSW 模型）是確立市場情緒具有定價影響力的理論基石⁵。該研究透過建構一個世代交替資產市場模型（Overlapping

Generations Model），將市場參與者明確劃分為兩個群體，並論證了情緒在資產定價中的機制：

第一類群體為「理性套利者」（Rational Arbitrageurs），他們基於資產的未來現金流與基本面進行評估，並擁有理性的貝氏預期。第二類群體為「雜訊交易者」（Noise Traders），這類投資人並不根據基本面交易，而是受到市場情緒、謠言、甚至偽造的技術訊號（即所謂的「雜訊」）所驅動，並抱持著錯誤的隨機信念⁶。

效率市場假說的擁護者通常認為，即使市場存在非理性的雜訊交易者，理性套利者也會透過套利行為（如買低賣高）迅速消除價格偏離，最終將雜訊交易者趕出市場。然而，DSSW 模型的突破性在於，它以數學推導證明了「雜訊交易者創造了套利者無法完全對沖的系統性風險」⁶。當雜訊交易者因為極端悲觀而拋售股票，導致股價低於其基本面價值時，理性套利者理論上應進場買進。但套利者面臨著一種不可預測的風險：雜訊交易者的悲觀情緒可能會在接下來的一段時間內變得更加極端，導致股價進一步非理性暴跌⁷。由於套利者的資金規模有限且面臨平倉壓力（例如避險基金面臨投資人贖回），這種被稱為「雜訊交易者風險」的不確定性，迫使套利者限制其部位規模，無法積極消除價格偏離⁷。

進一步而言，DSSW 模型指出，由於雜訊交易者承擔了由他們自己行為所創造的高額風險，在某些市場條件下，他們甚至可能獲得比理性投資人更高的預期報酬，這也解釋了為何雜訊交易者能夠長期存在於市場中而不會被消滅⁶。

對於「金融情緒與股價趨勢系統」而言，DSSW 模型提供了完美的學理護城河。系統中 PTT 爬蟲模組所抓取的股板閒聊、新聞評論，以及 AI 探索模組所定位的熱門財經詞彙，本質上正是量化「雜訊交易者群體信念」的最佳代理變數（Proxy）。透過自然語言處理技術擷取這些文本中的情緒，系統實際上是在衡量當前市場中的「雜訊交易者風險」水位，進而能夠預測資產價格偏離基本面以及後續均值回歸（Mean Reversion）的趨勢。

特徵面向	傳統效率市場假說 (EMH)	行為財務學 (DSSW 雜訊交易者模型)	專案系統之對應工程實踐
價格驅動核心	完全由基本面與新資訊決定，價格即價值	受基本面與雜訊交易者情緒共同交互影響	整合 API 歷史價量資料（均衡結果）與爬蟲文本情緒（雜訊變數）
投資人行為假設	資訊對稱下，所有投資人皆表現為完全理性	市場中存在大量基於情感與認知偏見的雜訊交易者	針對 PTT 股板閒聊與市場新聞標題進行情緒評分與追蹤
價格偏離現象	價格隨時處於均衡狀態，不存在無風險套利空間	雜訊交易者風險阻礙套利，導致價格長期偏離基本面	利用機器學習模型捕捉極端情緒指標與後續股價反轉的非線性關聯
市場預測可能性	股價遵循隨機漫步，	群眾情緒具備傳染	建構多維度特徵工程

	過去資訊無法預測未來	性、持續性與群聚性，具備預測價值	與預測模型，判定隔日或未來的漲跌趨勢
--	------------	------------------	--------------------

經典實證研究與情緒量化指標設計

確立了情緒影響價格的理論基礎後，學術界在過去二十年內產出了大量將網路文本量化為情緒指標，並檢驗其與股市表現關聯性的實證研究。將這些學術界打磨成熟的量化公式引入系統的轉換層（Transform Layer），將能顯著提升資料工程專案的商業價值與學術深度。

網路留言板的情緒解析：看多指數與一致性指數

Antweiler 與 Frank (2004) 發表於頂級期刊《The Journal of Finance》的研究，被視為利用計算機語言學（Computational Linguistics）分析股票留言板的先驅之作¹⁰。該研究團隊抓取並分析了 Yahoo! Finance 與 Raging Bull 兩個主要網路論壇上，涵蓋 45 檔指標性股票（包含道瓊工業指數成分股與科技股）超過 150 萬條留言訊息¹¹。在自然語言處理技術尚處早期的年代，他們採用了樸素貝氏（Naive Bayes）與支持向量機（Support Vector Machine, SVM）等經典演算法，將每一篇文本分類為「看多」（Bullish）、「看空」（Bearish）或「中立」（Neutral）三個類別¹¹。該研究的卓越貢獻在於，它並非單純停留在單篇文本的分類，而是提出了兩個極具工程實用性的時間序列聚合指標（Aggregation Metrics），能夠完美轉換為本系統中存入 PostgreSQL 的關聯特徵。

首要指標為「看多指數」（Bullishness Index）。該指數用於衡量在特定時間區間 t 內，市場投資人對於特定股票的整體情緒偏向。最基礎的公式是透過看多與看空留言的相對比例來計算：

$$B_t = \frac{M_t^{BUY} - M_t^{SELL}}{M_t^{BUY} + M_t^{SELL}}$$

其中 M_t^{BUY} 代表在時間 t 內被分類為看多訊號的訊息總數， M_t^{SELL} 則代表看空訊號的訊息總數¹⁰。為了處理社群媒體上訊息數量可能呈現指數型爆發（例如發生重大併購案時留言激增）的非線性問題，後續的學術研究更廣泛採用經過對數轉換與平滑處理的標準化看多指數公式：

$$B_t^* = \ln \left(\frac{1 + M_t^{BUY}}{1 + M_t^{SELL}} \right)$$

或在需要考慮訊息總量規模時使用的衍生公式：

$$B_{i,t}^* = \ln \left[\frac{2 + M_{i,t}(1 + B_{i,t})}{2 + M_{i,t}(1 - B_{i,t})} \right]$$

這種對數轉換確保了極端留言量不會導致特徵數值溢位，為機器學習模型提供了更為穩定的輸入特徵¹⁰。

第二個關鍵指標為「意見一致性指數」（Agreement Index），用於衡量市場投資人對於該檔股票的多空分歧程度。其數學定義如下：

$$A_t = 1 - \sqrt{1 - B_t^2}$$

當市場意見高度一致（幾乎所有人皆看多或皆看空）時，該指數會趨近於 1；反之，當市場多空交戰極為激烈、意見分歧嚴重時，指數將趨近於 0¹⁰。

Antweiler 與 Frank 的實證結果帶來了深刻的商業洞見。他們發現，網路論壇的看多指數與留言總數量，能夠在日頻率（Daily Frequency）上顯著預測下一期的「交易量」（Trading Volume）與「市場波動率」（Volatility），特別是散戶參與度高的小型交易規模會顯著增加¹¹。然而，在預測「股票報酬率」（Stock Returns）的絕對方向上，其統計顯著性雖然存在，但經濟規模（Economic Magnitude）相對較小，難以直接轉化為簡單的無風險套利策略¹¹。

這項結論為本系統的 ETL 轉換層與後續特徵工程提供了明確的指引：在構建資料庫 Schema 時，

不能僅儲存情緒分數，而必須將 B_t^* 與 A_t 分別計算並寫入；在構建特徵集時，不應僅將情緒作為預測漲跌的唯一特徵，而必須結合前幾日的交易量與歷史波動率指標，形成多維度特徵，因為情緒對波動率的預測力往往強於對價格絕對值的預測力。

微網誌情緒與大盤趨勢的關聯性探勘

隨著社群媒體進入微網誌（Microblogging）時代，資料頻率與傳播速度呈幾何級數增長。Bollen, Mao, 與 Zeng (2011) 發表的研究《Twitter mood predicts the stock market》在學術界與量化投資界引發了巨大的迴響³。該研究提取了每日規模龐大的 Twitter 串流資料，並採用兩種獨立的情緒追蹤工具進行深度文本分析：第一種是 OpinionFinder，主要用於衡量傳統的正向與負向情緒極性；第二種是 Google-Profile of Mood States (GPOMS)，該工具將人類心理情緒細分為六個更細緻的維度：平靜（Calm）、警覺（Alert）、確信（Sure）、活力（Vital）、友善（Kind）與快樂（Happy）³。

透過嚴謹的葛蘭傑因果關係檢定（Granger Causality Analysis），研究團隊檢驗了這些時間序列是否具有因果預測力，隨後運用自組織模糊神經網路（Self-Organizing Fuzzy Neural Network）將這些情緒特徵與道瓊工業平均指數（DJIA）的收盤價變動進行擬合。令人震驚的研究結果顯示，加入特定的公眾情緒維度（尤其是「平靜 Calm」與「快樂 Happy」），能顯著改善大盤指數預測的準確性。該模型在預測 DJIA 每日上漲或下跌趨勢的準確率高達 87.6%，並使平均絕對百分比誤差（MAPE）顯著降低了超過 6%³。

這項研究極大地鼓舞了情緒分析領域，確立了「集體情緒狀態（Collective Mood States）可作為經濟指標預測因子」的論點²⁰。然而，對於嚴謹的資料工程師與機器學習從業者而言，這項研究

後續引發的學術爭議，提供了更具價值的工程警訊。

在後續的學術檢驗中，發表於 Econ Journal Watch 的重新驗證論文對 Bollen 的結論提出了強烈質疑。研究者嘗試使用相同的時間窗格與資料處理技術，甚至將資料樣本向後延伸，卻發現無法重現最初報告的顯著 p-value 模式²³。後續研究發現，在樣本外（Out-of-sample）數據中，這些 Twitter 情緒指標對於預測股市的幫助微乎其微。這暗示了 Bollen 原本高達 87.6% 的準確率，很可能深受資料探勘偏誤（Data Snooping Bias）與過度擬合（Overfitting）的影響。在實務界，基於該篇論文理念於 2010 年底高調成立的量化避險基金 Derwent Capital Markets，也在實際市場中遭遇挫敗，並於 2012 年初黯然關閉²³。

這段從學術狂熱到實務挫敗的歷程，對本專案的機器學習層（Phase 3）規劃具有決定性的影響：

1. **高度警惕過度擬合與資料洩漏**：情緒與股價的關係是非線性且隨市場體制（Market Regime）動態變化的。模型在歷史訓練集上的高準確率毫無意義，嚴禁在時間序列資料上使用傳統的隨機抽樣進行交叉驗證。
2. **避免依賴單一靜態詞典**：早期的 GPOMS 等靜態情緒詞典難以適應金融市場不斷變化的術語與反諷語氣。本系統導入 LLM API 進行情感解讀¹，能更準確地理解語境，這是對傳統方法的重大技術升級。
3. **情緒的滯後效應（Lag Effect）**：基於葛蘭傑因果檢定的原理²⁴，情緒的影響往往具有時間遞延性。系統的資料管線必須在特徵工程階段，自動構建情緒分數的滾動滯後變數（如 sentiment_lag_1, sentiment_lag_3）。

台灣在地化觀點：PTT 股板與語言模型的演進

將視角拉回本系統專注的台灣股票市場與 PTT 股板，近年來大量本土學術論文同樣印證了網路輿情在台股定價中的影響力。實證研究表明，極端的網路關注度（如 PTT 股票板即時在線人數的激增）與股市交易量波動具備顯著的正向關聯，影響程度可達 12.51%，這充分證實了散戶投資者會因極端關注度事件而增加實質的交易行為²⁶。此外，針對特定單一標的（如台積電），在 PTT 上討論的聲量越高，其交易資訊的參考價值往往也越大；但研究也警告，這類群眾智慧（Crowd Wisdom）在牛市中表現優異，在熊市中則容易受恐慌情緒反噬而變得脆弱²⁷。

在自然語言處理技術的演進上，台灣本土研究經歷了從傳統詞袋模型（Bag-of-Words）、詞頻-逆向檔案頻率（TF-IDF）與潛在語意分析（LSA），過渡到 Word2Vec 詞向量技術，再演進至使用中文預訓練語言模型（如 BERT, RoBERTa）的歷程²⁸。最新的前沿研究更是直接整合了大型語言模型（LLM, 如 ChatGPT/Gemini）的強大推理能力，執行精細的情感判斷與關鍵字抽取。研究證實，融合 LLM 所萃取的市場情緒特徵，搭配機器學習模型，能顯著克服傳統方法難以反映即時市場情緒與潛在風險訊號的劣勢，特別是在受新聞事件高度驅動的半導體產業鏈中，能大幅提升對台股漲跌預測的精確率與穩定性³⁰。

本專案系統在轉換層設計的「Hybrid NLP 管線」，利用 SnowNLP 進行初篩過濾，再將難以判定的模糊地帶打包為 JSON 批次呼叫 gemini-flash-latest 模型，最後比對 PostgreSQL 快取表去重¹。此一架構完美契合了當前學術界「結合高速詞典與 Transformer 深度模型」以平衡精準度與 API 運算成本的混合模型（Hybrid Model）趨勢²²。

系統架構與自動化 ETL 資料管線之對齊實踐

為使專案在資料工程的專業評估中脫穎而出，必須確保上述學術理論能無縫轉譯為實際的程式碼與系統架構設計。本系統由主程式 main_etl_pipeline.py 擔任指揮官，協調 Extract, Transform, Load 三大子系統的運作¹。

收集層 (Extractors)：廣泛捕捉雜訊足跡

系統的收集層由多個物件導向 (OOP) 封裝的模組組成，包含負責抓取外部 API 的 `yfinance_api.py` 與 `twse_scraper.py`，以及專注於網路爬蟲的 `ptt_scraper.py`¹。根據 DSSW 模型的理論架構，API 所抓取的每日歷史價量資料，代表了市場理性與非理性交織後的「最終均衡價格」；而 PTT 爬蟲所獲取的文本，則忠實記錄了「雜訊交易者的行為足跡與預期」。系統中規劃的 `trend_discover.py` 模組尤其具備學術前瞻性。該模組旨在透過 AI 自動探索熱門財經詞彙，動態擴充 PTT 爬蟲的追蹤關鍵字池¹。這呼應了行為財務學中市場關注度 (Attention) 與流動性槓桿 (Liquidity Leverage) 瞬間爆發的特性，確保系統不會遺漏如「GameStop 事件」這類由社群媒體突發驅動的市場異常波動²²。此外，收集層全面導入了 `tenacity` 套件實作指數退避 (Exponential Backoff) 重試機制，強韌地防禦了 API 端點的速率限制 (Rate Limiting) 與 429 錯誤，展現了企業級 ETL 必備的高可用性防呆設計¹。

轉換層 (Transform) 與聚合邏輯

在 `data_cleaner.py` 與 `nlp_processor.py` 中，原始資料面臨清洗、時間格式對齊與商業邏輯轉換。在整合學術文獻後，轉換層的核心任務不僅是產出每一篇文本的 `sentiment_score`，更必須執行時間序列的聚合 (Aggregation) 運算：

1. **文本極性判定與計數**：系統接收 LLM 產出的 JSON 格式分數後，設定合理的閾值（如分數大於 0.6 標記為 BUY，小於 0.4 標記為 SELL）。
2. **聚合與指標生成**：針對每日每一檔股票代碼，在清洗矩陣中即時套用 Antweiler 的公式，

計算出每日的對數看多指數 $B_{i,t}^*$ 與一致性指數 A_t 。

3. **處理缺失值與遺漏**：若某日該檔股票完全無人討論（缺失觀測值），依據學術實證經驗，應填補為 0 或是使用上一期的中位數，以維持時間序列的連續性³²。

載入層 (Loaders) 與快取機制

在巨量文本運算中，將每一次 API 請求皆即時傳送至雲端 LLM 進行運算是極度缺乏成本效益的。系統中的 `db_writer.py` 管理了 `sentiment_cache` 資料表¹。當處理大量被轉發的相同新聞標題或高度相似的推文時，系統會先向 PostgreSQL 的快取表進行查詢，若該句型的語意特徵已存在，則直接讀取快取分數。

這項設計不僅大幅降低了 API 呼叫成本與網路延遲，更解決了學術上潛在的「情緒聚合偏誤」問題。若不對高度重複的轉發訊息進行過濾，某些機械式轉發的標題將在當日的情緒總分中取得過高的權重，導致情緒指標失真。配合 `psycpg2` 的 `execute_values` 批次寫入功能，以及基於複合主鍵的 `ON CONFLICT DO UPDATE` 語法，系統達成了嚴格的冪等性 (Idempotency)，確保爬蟲腳本即使因斷線重啟或重複執行，資料庫也不會產生髒資料¹。

機器學習層與特徵工程的演算法決策

在完成 ETL 流程，進入規劃中的機器學習層 (Phase 3 - `model_trainer.py`) 時，系統的任務是運用過去 N 天的股價變化特徵與情緒分數特徵，預測隔日股價的漲跌趨勢¹。此階段的成敗，取決於特徵工程的細緻度與演算法的選擇。

特徵工程：融合技術指標與情緒動能

基於前述 Bollen (2011) 與多項實證研究，情緒對資產定價的影響極具非線性與遞延性。因此，輸

入至機器學習模型的資料集，應透過特徵工程擴充為多維矩陣。除了原始的開高低收（OHLC）價格外，必須整合以下關鍵特徵：

- **技術面動能指標：**包括高達 30 天的對數報酬率滯後變數（Lagged log-returns）、14 期的相對強弱指數（Relative Strength Index, RSI），以及短中期（如 5 日與 20 日）的滾動波動率（Rolling Volatility）³³。
- **情緒面動能指標：**將轉換層計算出的看多指數 B_t^* 與一致性指數 A_t 進行平滑處理，建立 1 日、3 日、5 日的情緒移動平均與滯後（Lag）特徵，以捕捉散戶情緒在社會群體中的動能擴散與發酵效應¹⁹。

模型決策：Random Forest 與 XGBoost 的對決

在處理包含情緒與價量特徵的表格型時間序列資料（Tabular Time Series Data）時，樹狀整合模型（Tree-based Ensemble Models）是目前學術與業界最受青睞的演算法，遠勝於傳統的邏輯斯迴歸（Logistic Regression）或支援向量機（SVM）³⁴。專案應考慮平行實作隨機森林（Random Forest）與極限梯度提升樹（eXtreme Gradient Boosting, XGBoost）進行效能比較。

- **Random Forest:** 透過 Bootstrap 抽樣機制與特徵隨機選擇來建構多棵獨立的決策樹。金融數據中充斥著因極端事件導致的異常值（Outliers），Random Forest 利用群體決策降低變異數，對高波動性資料與雜訊具有極強的抵抗力。學術比較研究指出，在引入複雜特徵後，Random Forest 能夠有效防止過度擬合，在長期的預測準確率與均方誤差（MSE）表現上十分穩健³⁶。
- **XGBoost:** 基於梯度提升（Gradient Boosting）框架，XGBoost 採用循序漸進的方式，每一棵新建立的樹皆致力於修正前一棵樹的殘差錯誤。其優化的目標函數為

$$Obj = \sum L(y_{true}, y_{pred}) + \Omega(f)$$

，其中巧妙融合了衡量預測誤差的損失函數，以及懲罰模型複雜度的正則化項（Regularization Term）以防止過度擬合³⁶。XGBoost 對於捕捉特徵之間的非線性交互作用極具優勢（例如：當「高波動率」疊加上「極端看空情緒」時，往往是強烈的反轉訊號）。此外，它內建的特徵重要性（Feature Importance）評估工具，能直接量化 LLM 情緒分數在整個預測模型中的實際貢獻度，提供強大的模型可解釋性³³。然而，XGBoost 對輸入變數的尺度與超參數設定極為敏感，調校難度較高³⁶。

演算法特性	Random Forest (隨機森林)	XGBoost (極限梯度提升樹)
學習機制	Bagging (降低 Variance)，平行建構多棵樹	Boosting (降低 Bias)，循序修正殘差誤差
對雜訊的容忍度	較高，不易因極端股價或情緒雜訊過度擬合	依賴正則化項，若超參數未調校好易過度擬合
特徵交互作用捕捉	良好，決策樹自動捕捉非線性關係	極佳，在處理高維度複雜特徵上表現優異

模型可解釋性	支援特徵重要性評估，但難以追蹤單一決策路徑	內建強大的特徵增益評估，高度適合分析情緒特徵貢獻
--------	-----------------------	--------------------------

嚴格的模型驗證機制與商業價值評估

前述 Bollen 論文衍生的實務挫敗，凸顯了金融預測模型中最致命的錯誤：未來函數洩漏（Look-ahead Bias）。在評估 Phase 3 的預測模型時，驗證機制的嚴謹度將直接決定本系統是屬於「業餘的學術實驗」，抑或是「符合專業量化基金標準的基礎設施」。

防禦資料洩漏：Walk-Forward 交叉驗證

在一般機器學習專案中，開發者常使用隨機切分的 K-Fold 交叉驗證。然而，將 K-Fold 應用於金融時間序列會將未來的資料段落作為訓練集，去預測過去的測試集，這完全違背了時間的不可逆性，導致模型在訓練時表現完美，上線後卻瞬間崩潰⁴⁰。

為確保專業度，系統必須強制實作「滾動前向驗證」（Walk-Forward Validation，或稱 Time Series Cross-Validation）。在 Python 生態系中，可直接導入 scikit-learn 的 TimeSeriesSplit 模組來達成⁴¹。

Walk-Forward 驗證的運作邏輯如下：

1. 確保所有特徵資料嚴格依照時間戳記遞增排序。
2. 採用擴展視窗（Expanding Window）策略：在第 k 次迭代中，模型僅使用從起點到時間 t 的資料作為訓練集，並在 $t + 1$ 的區間進行驗證測試。下一次迭代，訓練集將擴展至 $t + 1$ ，並測試 $t + 2$ ，如此滾動前進⁴¹。
3. 為進一步防止相鄰時間點的資料產生自相關性洩漏，實務上可設定 $\text{gap} > 0$ 的參數（如引入 `tscv.GapRollForward`），在訓練集與驗證集之間強制留下一段時間緩衝⁴⁰。

這種驗證策略完美模擬了現實交易中「利用過去至今的所有歷史資料，去預測未知明天」的真實情境，確保了模型預測效度的實務可信度⁴³。

專業評估指標：超越單純準確率

在規劃系統最後階段的 BI 互動式儀表板（Phase 4 - Dashboard）時，用以呈現模型績效的指標必須超越基礎的準確率（Accuracy）²。股市在多頭市場中天生具備上漲偏誤，盲目預測上漲即可獲得超過五成的準確率。因此，除了精確率（Precision）、召回率（Recall）與均方誤差（RMSE, MAE）外³⁵，儀表板應引入更專業的量化金融評估維度：

- **資訊係數 (Information Coefficient, IC):** 用以衡量模型預測的股價報酬（或上漲機率）與未來實際股價報酬之間的皮爾森相關係數。IC 值是專業量化基金評估選股模型預測能力的核心標準。一個具備穩定正向 IC 值的模型，證明其確實具備產生超額報酬（Alpha）的統計能力⁴⁵。
- **夏普比率 (Sharpe Ratio):** 衡量承受每單位總風險所產生的超額報酬。即便情緒預測模型的整體準確率並不驚人，但若該模型能精準捕捉到極端負面情緒的爆發，並發出下跌警告，幫助系統避開大幅度的市場回撤，其產生的風險調整後報酬（Risk-adjusted Return）

仍可能極其卓越⁴⁵。

透過將嚴謹的行為財務學基礎、被廣泛驗證的情緒量化公式，以及防禦未來資料洩漏的機器學習交叉驗證策略深度融合入系統程式碼中，本「金融情緒與股價趨勢系統」將不僅僅展示卓越的資料工程實作能力，更展現了跨領域整合與建構機構級量化分析平台的深厚底蘊。

